

コーパスに基づく「読解基本語彙 1 万語」の選定

本 田 ゆ か り

要 旨

本研究は、コーパスと統計による客観性を重視した方法で語彙リスト（以下、「読解基本語彙 1 万語」）を作成することを目的とする。コーパスから語彙の頻度や分布を集計する場合、結果にはコーパスの特徴がそのまま表れる。そのため本研究では、まず、利用するコーパスが日本語教育のための読解基本語彙リスト作成に適したものかを検証し、コーパスを再構成した。そこから語彙を頻度集計し、複数の統計指標によって重要度を定量化し、語彙をランキングした。最後に、日本語教育の観点からランクの再配列と限定的な調整を行った。

このようにして作成した語彙リストを評価するため、テキストカバー率調査を行った。また、「読解基本語彙 1 万語」と『日本語能力試験出題基準』（国際交流基金・日本国際教育支援協会編 1994, 2002 年改訂, 以下、「出題基準」）とのカバー率比較も行った。その結果、「読解基本語彙 1 万語」は「出題基準」に比べて高いカバー率を示した。

【キーワード】 コーパス, 基本語彙, 語彙リスト, 散布度, テキストカバー率

1. はじめに

日本語教育では、これまで数多くの語彙リストが作られてきた。教育語彙表には大きく分けて二通りの作成理念がある。一つは「学習順序・学習段階に合わせて語彙を選ぶ」というもの、もう一つは「将来的に知っておいた方がよい語彙を言語使用の実態を見て選ぶ」という考え方である。前者はこれまでも多数作られてきたが、後者のタイプはまだ数が少ない。本研究はこの後者のタイプの語彙リストの作成に取り組んだものである。

本研究では、書き言葉の理解に特化した「読解基本語彙」のリストを作成したい。ここで言う「読解」とは、広義に書き言葉を読むことを指す。話し言葉と書き言葉ではコーパスの頻度や語彙の分布が異なるため、基本語彙として選定される語彙に違いがある。インターネットが普及している現在、日本国内だけでなく世界中の日本語学習者がニュースや書籍やブログの他、様々なタイプの日本語を読むことができる。本研究は、このような学習者の読みに効果的な語彙を選定することを目的としている。

2. 先行研究

従来、日本語教育では、戦後から行われてきた小規模な語彙調査の結果を参考資料とし、専門家の判断や判定によって語彙の選定を行うという方法（以下、専門家判定方式）で数

多くの語彙リストが作成されてきた。その代表的なものに「出題基準」の語彙セットがある。

このタイプの語彙リストは、基本的に「学習順序・学習段階に合わせて語彙を選ぶ」という理念に基づいている。しかし、このように専門家の「日本語教育的観点から適切または重要という考え」、いわゆる「主観」に基づいて作成された語彙リスト間の一致率は低いという報告もある(饗場2011)。これは、たとえ専門家であっても主観はそれぞれに異なり、教育語彙としての重要性を考える際に一致しない部分も存在することを示唆している。

これに対し、コーパスを参照して作られた語彙リストがある。コーパス準拠型は「言語使用の実態を見て語彙を選ぶ」という考え方に基づく。この例には「日本語を読むための語彙データベース」(松下2011)や、「日本語教育語彙表」(李・砂川2012)がある。

李・砂川(2012)は、『現代日本語書き言葉均衡コーパス』(以下、BCCWJ)と日本語教科書コーパス⁽¹⁾をもとに作られた語彙リストで、総語数約2万語を収録している。これはコーパス準拠型であるが、語彙選定やレベル分けでは専門家判定方式も採用している。

松下(2011)の「教育用」語彙リストは総語数約6万語で、その上位2万語は1000語区切りで20段階のレベルに分けられている。語彙選定にはJuilland et al. (1970)の*D*という散布度指標が使われている。また、コーパスはBCCWJ 2009年公開モニター版が利用されている。このコーパスの規模は約3300万語で、テキストは書籍とWebの2種類である。

投野・本田(2016)は、コーパス準拠の語彙リスト作成方法について次のように述べている。「教育語彙表を構築する基礎となるコーパス・データの収集が語彙表作成の大きなポイントになる。この場合、教育語彙表の使用目的に応じて標本抽出(sampling)、代表性(representativeness)、均衡(balance)という三つの概念を考慮することになる。大きな方法論として、コーパス構築の段階で綿密な設計を行い、分野バランスなども十分に考慮に入れて構築されたコーパスの頻度をそのまま語彙表として採用する方法と、コーパスからの頻度は一つの参考情報として用い、それ以外の様々な指標と絡めて総合的に判断するため、コーパスの構築自体は比較的大まかな設計で行うという二つのやり方がある。どちらの場合にせよ、『入れたものが出てくる』というコーパスの必然的な特徴を十分に理解してコーパスに含める資料の吟味は適切に行わなければならない。」(投野・本田2016, p.39) また、コーパス・サイズが抽出する語数に対して十分な規模を確保していることも重要な点である。

先行研究を見ると、専門家の直感によって語彙を収集するタイプの語彙リストは数多くあるものの、頻度や分布統計などの客観的な根拠に基づいて言語使用実態を反映させようとするタイプの語彙リストが少ない。また、コーパス準拠の日本語教育語彙リストを作るにあたり、利用するコーパスが目的とする語彙を収集できるかどうかに関してコーパスそのものの検証作業を綿密に行うことは一般的ではない。しかし、コーパスの頻度や分布などの統計情報を重視して教育語彙リストを作る場合、その時に入手できるコーパスをそのまま利用するだけでは不十分である。語彙リストの規模や語彙レベルの分け方などにも検討の余地がある。これらの課題に取り組むことによって、従来型とは質的に異なる、学習者が日本語の書き言葉を読むうえで実際に役立つ語彙リストを作成することができるのではないだろうか。

3. 研究方法

本研究では、コーパスと統計指標に基づき、日本語教育語彙リスト「読解基本語彙1万語」を作成する。「読解基本語彙1万語」は内容語のリストとして作成し、機能語は含めない⁽²⁾。以下、語彙リストの大まかな作成方法とデザイン（総語数、掲載情報）について記す。

語彙リスト作成方法の概要は次の通りである。まず、コーパス・データを本研究の目的に照らして吟味する。本研究は読解基本語彙を選定するため日本語の書き言葉コーパスであるBCCWJを利用するが、コーパス・データの検証作業を行い、必要に応じてサブコーパスのバランスを変えて再構成する。語彙選定は作成者の主観的判断を最小限に、複数の統計指標と絡めて行う。この再構成したコーパスを集計し、頻度と分布統計を出し、語彙をランキングする。この語彙の頻度と分布の情報をもとに、教育語彙リストとして意味のあるレベル分けとなる語数のまとまりは何語区切りであるかを検討する。このように語数設定した各レベルに語彙を選定していく。その際、頻度と分布だけで配列した語彙リストに日本語教育的な難易度も加味した定量的な基準による調整も行う。最後に、語彙リストを評価するため、テキストカバー率調査を行う。

語彙リストの総語数は1万語とする。本研究の語彙リストは、語彙の出現頻度と分布統計が選定の主な基準となる。一般的に、低頻度語彙や分布の安定しない語彙はコーパス・サンプリングによってランクが大きく移動することが見込まれる。そのため、これらをレベル分けして提示しても、その根拠は必然的に薄くならざるを得ず、教育的にあまり意味がないと言える。日本語能力試験とその出題基準語彙リストの改訂もあり、松下(2011)や李・砂川(2012)のように2万語以上を示す例もあるが、本研究では、低頻度語彙の選定に無理のない範囲として総語数を1万語としたい。語彙リストに掲載する情報は、見出し語、読み、品詞、語種、語彙レベル、重要度ランク、散布度、単語親密度(天野・近藤1999)とする。

4. 結果と考察

ここでは結果についてまとめ、考察する。以下、コーパスの検証と再構成(4-1)、頻度と分布統計による語彙のランキング(4-2)、レベル分け(4-3)、単語親密度による難易度ランクの補正と日本語教育的観点からの調整(4-4)、テキストカバー率調査(4-5)の順に述べる。

4-1 コーパスの検証と再構成

本研究では、2011年に公開されたBCCWJ(総語数約1億語)を利用する。BCCWJは、日本語の書き言葉を収集したコーパスであり、本研究の目的である書き言葉を読む際に有用な語彙(理解語彙)を抽出することにも適している。一方、BCCWJは日本語母語話者の言語世界の縮図という意味における均衡コーパスであり、日本語学習者にとってもそれが同じであるとは限らない。そこで本研究では、まずこのコーパスが、日本語学習者がテキストを読む際に役立つ語彙を選定するという目的にも合うものかどうかを検証し、その結果を踏まえて各レジスターの語数の割合の再構成を試みた。その方法は、以下の通りである。

BCCWJは、「出版サブコーパス」「図書館サブコーパス」「特定目的サブコーパス」という三つのサブコーパスから成り、13種類のテキストジャンル(レジスター)⁽³⁾を収録している。この各レジスターに含まれる語彙には、それぞれ特徴がある。そこで、レジスターが違

うと、どの程度語彙の頻度ランクに移動が起こるのか、また、語彙分布傾向が著しく異なる、または類似傾向にあるのはどのレジスターかを確認するため、レジスターごとの語彙的な重なりを調査した。この調査では、各レジスター（11種類⁽⁴⁾）からそれぞれ約100万語ずつをランダムサンプリングして語彙を頻度集計し、頻度ランク順で1000語ごとに区切り、媒体間の語彙の重なり（語数）を見た。ここでは、1万語の範囲における調査結果を示す（表1）。

表1 頻度上位1万語までの重なり語彙（語数）

重なる媒体	書籍 LB	書籍 PB	雑誌 PM	新聞 PN	ベスト OB	知恵袋 OC	会議録 OM	広報紙 OP	教科書 OT	白書 OW	ブログ OY
1種類	1085	991	888	841	1553	1514	1688	1573	1693	1709	1103
2種類	771	768	726	784	910	1065	1088	910	862	1173	877
3種類	692	693	751	759	743	766	802	743	698	869	743
4種類	648	694	729	760	621	668	629	660	620	697	702
5種類	693	680	690	712	577	617	578	625	566	631	651
6種類	690	671	710	710	588	566	548	578	531	590	676
7種類	698	722	720	692	614	568	532	559	573	508	667
8種類	759	807	789	773	634	587	566	622	657	535	711
9種類	898	893	920	887	789	714	648	740	776	582	829
10種類	1122	1137	1133	1138	1027	991	977	1046	1080	762	1097
11種類	1944	1944	1944	1944	1944	1944	1944	1944	1944	1944	1944
総計	10000	10000	10000	10000	10000	10000	10000	10000	10000	10000	10000

表1の通り、全レジスター（表中の「11種類」）に共通して出現する語彙は、頻度上位1万語中、全体の20%以下（1944語）であり、どのレジスターにも安定して高頻度で出現する語彙はあまり多くないことが明らかになった。

レジスターごとに見ると、「特定目的サブコーパス」の語彙は他のレジスターとの重なりが小さいのに対し、書籍、新聞、雑誌などは比較的重なりが大きい。それぞれの特徴語を質的な側面からも詳しく見たところ、国会会議録、白書、広報紙、ベストセラー、Yahoo!知恵袋、検定教科書には専門語彙⁽⁵⁾が多いという傾向が把握できた。中でも国会会議録、白書、広報紙には、日本語教育的な重要度は低いと考えられる専門語彙が顕著に見られた。

この傾向をより客観的に把握するため、頻度上位1万語をクラスタ分析し、レジスターのグルーピングを行った。その結果、国会会議録、白書、広報紙は他のレジスターとの類似性が薄く、独立したグループとなった。一方、ベストセラー、Yahoo!知恵袋、検定教科書には、このような特徴は見られなかった。

この結果を踏まえ、コーパス全体から上記六つのレジスターの語数を、それぞれ割合を定めて減らすという方法でバランス調整を行った。その際、ベストセラー、Yahoo!知恵袋、検定教科書の三つと国会会議録、白書、広報紙の三つを分けて考え、縮小する割合を検討した。

方法は次の通りである。まず、表1における各レジスター独自（表中の「1種類」）に出現する語彙、および他の1種類までとしか重ならない（表中の「2種類」）語彙の数を集計し、その平均値を求めた。この1種類と2種類の語彙の合算を仮に「レジスター特有の語彙」と

する。この平均値から、各レジスターの特有の語彙の割合がどの程度離れているかによって、語数の削減割合を決定した(表2)。例えば、白書が含む特有の語彙の割合は28.8%、特有の語彙の割合の平均値22.3%との差は6.5%である。このように、六つのレジスターについて平均との差を求めた。次に、削減の割合であるが、全体からほんの数パーセント語数を削減しても、頻度集計結果にはほとんど影響が出ない。そこで、この平均値との差をそれぞれ10倍して白書は65%、広報紙は25%というように削減割合を決めた。恣意的な操作ではあるが、こうすることによって特殊な媒体の語数を削減したことが全体の集計結果にも反映され、特有の語彙が多い媒体ほど語数削減の割合を大きく、少ないものは小さくするという原則に基づいて調整することができる。

一方、ベストセラー、Yahoo!知恵袋、検定教科書の三つのレジスターに関しては、特有の語彙を多く含みつつも他の媒体との類似性も確認でき、特有の語彙自体も質的に見ると本研究の語彙リスト作成の目的に適合しないものばかりではない。そのため、先の三つのレジスターほど大幅にならない程度に、削減する割合は平均の差に対して5倍の値とした。これも恣意的だが、前述の三つのレジスターより小規模に、日本語教育的な重要性に比例する割合で語数削減を行っている。

表2 コーパスから削減する割合と語数

	ベストセラー OB	会議録 OM	Yahoo!知恵袋 OC	広報紙 OP	検定教科書 OT	白書 OW
削る割合(%)	11%	54%	17%	25%	16%	65%
語数(万語)	43	277	177	94	15	316

このような語数削減を行い、コーパス・バランスに調整を加えると全体は表3のようになり、総語数は約9463万語になった。

表3 調整前と調整後のコーパス・バランス

媒体	調整前		調整後	
	語数(万語)	割合(%)	総語数(万語)	割合(%)
書籍(PB)	2,855	27.2%	2,855	30.2%
雑誌(PM)	444	4.2%	444	4.7%
新聞(PN)	137	1.3%	137	1.5%
書籍(LB)	3,038	29.0%	3,038	32.1%
白書(OW)	488	4.7%	172	1.8%
検定教科書(OT)	93	0.9%	78	0.8%
広報紙(OP)	376	3.6%	282	3.0%
ベストセラー(OB)	374	3.6%	331	3.5%
Yahoo!知恵袋(OC)	1,026	9.8%	849	9.0%
Yahoo!ブログ(OY)	1,019	9.7%	1,019	10.8%
韻文(OV)	25	0.2%	25	0.3%
法律(OL)	108	1.0%	0	0.0%
国会会議録(OM)	510	4.9%	233	2.5%
合計	10,493	100.0%	9,463	100.0%

今回は、「均衡コーパス」である BCCWJ の割合を大幅に崩さないことを原則に、質的、量的な分析を踏まえ、一部のレジスターの語彙を削減することによって、コーパス・バランスを調整した。バランス調整後の内容を見ると、白書(OW)や国会会議録(OM)が新聞(PN)よりも多い。これには議論の余地があるが、どのようなバランスが最適であるかは同様の手順により複数の語彙リストを作ったうえでテキストカバー率調査などの評価を行い、さらに検討していく必要がある。これは今後の課題としたい。

4-2 頻度と分布統計による語彙のランキング

上記の方法で再構成したコーパスを頻度集計し、散布度 (dispersion) と有用度 (utility) の値を計算した。コーパスから基本語彙リストを作成する際には、高頻度であると同時に分布も安定した語彙を選ぶ必要がある。ある特定のテキストだけに高頻度で分布の安定しない語彙は、基本語彙というよりテキストに依存する専門語彙とも考えられるからである。

散布度と有用度にはそれぞれいくつかの指標があるが、本研究では散布度に DP を使用した。 DP は Gries (2008) が提唱する散布度指標である。教育語彙リストの開発では、Juilland's D や Carroll's D_2 などが古典的なものとして今でも利用されているが、Gries (2008) はこれらの問題点⁽⁶⁾を指摘し、 DP を開発した。

$$\text{Gries' } DP: \frac{\sum_{i=1}^n \left| \frac{v_i}{f} - \frac{S_i}{\sum S} \right|}{2}$$

DP は、ある言語特徴がサブコーパス⁽⁷⁾に出現する頻度をコーパス全体に出現する総頻度で割った値 (実測値) と、そのサブコーパスの総語数をコーパス全体の総語数で割った値 (期待値) の差を求め、その絶対値を足し合わせたものを2で割るという方法で算出される。 DP は0以上1以下の範囲で示され、0に近いほど分布が安定していることを示す。

有用度については次の通りである。散布度が分布の安定を示すものであるのに対し、有用度は一般に頻度と分布の2種類の指標を合成したものである。この有用度によって、リストの語彙を高頻度であると共に分布も安定したものからランキングすることが可能になる。既存の有用度指標を利用することもできるが、本研究では散布度指標に DP を用いるため、 DP の逆数に頻度の対数を掛けた値を有用度とした。 DP を逆数にした⁽⁸⁾のは、これが0に近いほど分布が安定していることを示す指標のためである。このようにして散布度と有用度を計算し、リストの語彙をランキングした。なお、「読解基本語彙1万語」は内容語のリストであるため機能語はここで削除した。また、固有名詞や、数詞などの対概念語⁽⁹⁾も除外した。

4-3 レベル分け

語彙レベルの分け方と各レベルの語数設定に関しても、原則的に頻度と分布の傾向に基づいて設定した。まず、頻度上位を1万語までを目安として1000語区切りの単位で累積頻度と DP 値の散らばりを見た。そして、各グループの頻度と DP の記述統計をもとにクラスター分析を行い、この結果を参考にレベル分けと語数設定を行った。

表4の頻度の最高値、最低値、標準偏差を見ると、高頻度語彙の部分ほど最高値と最低値の差が大きい。例えば、頻度ランク1～100までの頻度最高値は2,282,435、最低値は

36,997で、差は2,245,438である。一方、低頻度語彙の部分となる上位9001～10000では最高値が486、最低値が416でその差は70である。平均値でも頻度ランクが1～1000と1001～2000の間には大きな差があるが、それ以降の差は急激に縮小していく。

累積頻度と累積比率を見ると、上位1万語までの累積頻度は39,899,286であるが、上位100語までの累積頻度は13,832,121で全体の35%を占め、ここがコーパス中で最も大きな部分を占める語群と言える。累積比率は1000語で65%、2000語で77%、3000語で84%と比較的大きく上昇するが、それ以降は徐々に緩やかになっていく。このように上位1万語までの頻度分布を見ると、上位5000語まででほとんどの部分を占める。中でも上位1000語までの語群は最も大きなグループで、累積頻度の過半数がここに集中している。

表4 頻度ランク1万語までの累積頻度

頻度ランク	最高値	最低値	平均値	累積頻度	累積比率
1～100	2,282,435	36,997	138,321	13,832,121	35%
101～200	36,955	22,920	29,042	16,736,328	42%
1～1000	2,282,435	6,752	25,918	25,917,817	65%
1001～2000	6,738	3,489	4,801	30,718,493	77%
2001～3000	3,487	2,136	2,726	33,444,040	84%
3001～4000	2,136	1,491	1,786	35,230,309	88%
4001～5000	1,489	1,111	1,286	36,516,482	92%
5001～6000	1,111	873	985	37,501,859	94%
6001～7000	873	703	784	38,285,547	96%
7001～8000	703	577	636	38,921,707	98%
8001～9000	577	486	529	39,450,668	99%
9001～10000	486	416	449	39,899,286	100%

次に、散布度 (*DP*) の傾向についても調査した。その結果、語彙分布が比較的安定しているのは頻度上位1000～2000語の範囲までで、5000語以降はほとんどが分布の安定しない語群であることが把握できた。また、高頻度語彙の範囲では*DP*の最高値と最小値の差が大きいのに対し、5～6000語以降はそのような差が小さい。この結果を踏まえると、語彙のレベル分けを考える場合、高頻度語彙の集まる部分ではランクが異なれば頻度も散布度も大きな差が生じるのでレベル分けも意味のある区分になりえるが、低頻度になるほど頻度も散布度も近い値に集中するので、意味のあるレベル分けが難しくなることが予測できる。

この傾向をより明確にしてレベル分けの語数を設定するため、頻度ランク順で1000区切りにした1～10000語までの10のグループについて頻度と*DP*の最高値、最低値、平均値、標準偏差を変数としてクラスタ分析し、傾向別にグルーピングを行った。その結果を踏まえ、日本語教育における実用面も考慮に入れて設定したレベル分けが表5である。

表5 レベル分けの内容

大分類	レベル	日本語学習段階の目安（語彙表中の順位）	項目数（語数）	累積項目数
基本語彙	2000 語	初級後期～中級前期 (1 ～ 2000)	2000	2000
	4000 語	中級前期～中期 (2001 ～ 4000)	2000	4000
	6000 語	中級中期～後期 (4001 ～ 6000)	2000	6000
低頻度語彙	8000 語	中後期～上級 (6001 ～ 8000)	2000	8000
	10000 語	上級～ (8001 ～ 10000)	2000	10000

クラスタ分析では頻度ランク 1 ～ 1000, 1001 ～ 2000, 2001 ～ 3000, 4001 ～ 6000, 6001 ～ 10000 の 5 分類が一つの分け方として示された。大きくは、1 ～ 6000 までの基本語彙と言える範囲と、6001 ～ 10000 までの比較的低頻度の語彙の範囲に分けて考えることができる。この結果をもとに、語彙リスト作成上の様々な要素を考慮し、細かいレベル分けでは最終的に 2000 語区切りで 2000 語, 4000 語, 6000 語, 8000 語, 10000 語の 5 レベルで示した。

日本語学習者が学ぶ最初の 1000 語は、使用する教科書の影響を受けることが多い。初級日本語教科書では一般的に日常会話が重視されているので、その語彙は書き言葉コーパスから切り出された中核的 1000 語とは異なる。語の学習しやすさや難易度の問題もあるため、本研究は初級前期から重要度ランクの高い項目順に学習することを推奨するものではない。

しかし、最初のレベルを 2000 語までにすると、学習に合うかたちでこれを示すことができる。「出題基準」で初級修了程度とされている 3 級語彙の総数は、1500 語である。一方、「出題基準」には本研究で削除対象となっている語彙も含まれるため、2000 語レベルは一般的な「初級」以上で、初級の終わり～中級前期頃までをイメージすることができる。日本語学習ではこの時期に文章を読む機会も増える。2000 語レベルの語彙は、このような学習者に対して「知っている」と書き言葉の読みが効率的になる語彙」として提示することができる。

2000 語レベルの次に 4000 語レベルを設定した。さらに細かく区切るならば、3000 と 4000 の間でも分けるクラスタ分析の結果を重視した分類もある。しかし、頻度と分布によるランキングの後、単語親密度によって一部の項目をランク移動させることや、この前後のレベルも 2000 語で分けられること等を考慮すると、実用面や利便性を考えて、ここも 2000 語で区切るのが妥当であると考えた。3000 語 4000 語の間に 1000 語ごとの区切りはあるものの、4000 と 5000 の間にも区切りがあるので、4000 語レベルで分けること自体には問題はない。

その後の 6001 ～ 10000 はクラスタ分析の結果のままで 6000 語以降、低頻度語彙のレベルとして一つのグループにまとめられる。6001 ～ 10000 語の範囲には頻度と分布の観点から大きな違いはなく 4000 語でひとまとまりとなる。しかし、これ以前のレベルを全て 2000 語ずつでまとめたことや、テキストカバー率調査で「出題基準」との比較を行う際に 8000 語で一区切りあるほうがよい⁽¹⁰⁾ことから、便宜的に 8000 語と 10000 語を設定した。

4-4 単語親密度による難易度ランクの補正と日本語教育的観点からの調整

ここでは 4-2 の方法（有用度）でランキングした語彙を、日本語教育的な難易度の観点か

らランク補正した。本研究ではこれを単語親密度⁽¹¹⁾という定量基準を参照して行った。また、高頻度部分(2000語以内)については、それ以外の部分とは異なる調整も加えた。

単語親密度は、ある語が日本語母語話者にとってなじみ深く感じられるかどうかを1～7の7段階評価で示したもので、値が高いほど親密度が高いことを示す。これは日本語学習者にとっても身近である(易しい)ことを示唆し、日本語教育では語彙の難易度判定基準としてごく一般的に参照されている(徳弘2005, 川村2006, 押尾他2008)。高頻度語彙は単純接触効果によって親密度が高いことも過去の研究で明らかにされている(宮本・太田2008)。また、頻度が高いことは単語親密度が高いことの必要条件であり、特に話し言葉との相関が高いことが指摘されている(寺田・田中2008)。即ち、単語親密度の高い語彙は高頻度で、話し言葉的な日常語彙であることが、先行研究によって示されている。このような語彙は学習者にとっても接触する機会の多い身近な、易しいものであると考えることができる。

単語親密度は、低頻度部分に多く集まりやすい日常語彙のランクを上位に調整する際に有用である。ただし、単語親密度は日本語教育的な語彙の難易度を示すものとして開発された指標ではないため、そのまま利用できない部分もある。本研究では「文字音声単語親密度」を参照したが、例えば、表記の影響で単語親密度が極端に低くなっていると見られる項目は「音声単語親密度」を参考にするなどして利用した。⁽¹²⁾

ランク調整はレベルごとに行った。有用度ランク順に配列した語彙リストの中で、例えば上位2000語を選定する際には、有用度ランク上位3000語までを範囲とし、単語親密度順に再配列して上位2000語を決定するという方法を取った。+1000語という範囲は目安として恣意的に定めた。原則的にこの方法で5レベルを選定した。

一方、高頻度語彙には別の方法も用いた。有用度ランキング上位100語に位置する語彙はコーパスの中核とも言え、単語親密度によるランク調整を行わずそのまま残した。この範囲の単語親密度には、日本語教育的な難易度と直観的に合致しない例も少なくない。例えば、「する」(文字音声:3.281, 音声:5.094),「促(まま)」(文字音声:3.375, 音声:4.75)などは有用度が高く、日本語教育的にも基礎的な語彙だが単語親密度は低い。この理由は明確ではないが、リストの表記だけではなく、多義語であることや、同音異義語が存在することなどの関与も推測される。先にも述べたように単語親密度にはそれ自身の特徴や傾向があり、上位100語までの語彙には単語親密度による調整が適切に働かないケースが目立つ。このような理由から、この範囲を調整外とした。なお、初級文型とリンクする語彙についても、最小限の範囲で2000語レベルに入るよう少数の項目を操作した。

このような方法で調整した結果、各レベルの有用度と単語親密度は表6のようになった。

表6 各レベルの有用度と単語親密度

レベル	有用度・平均値	単語親密度・平均値	単語親密度・閾値
2000語	16.01	6.158	5.844
4000語	9.87	5.871	5.514
6000語	8.10	5.681	5.281
8000語	7.20	5.524	5.031
10000語	6.58	5.394	4.781




図1 各レベルの単語親密度の平均値

単語親密度の平均値は2000語レベル6.158, 4000語レベル5.871, 6000語レベル5.681, 8000語レベル5.524, 10000語レベル5.394となった。レベル間の差は2000語レベルと4000語レベルの間でやや大きく, 10000語レベルに向かってその差が小さくなり緩やかに下降する傾向が見られた(図1)。

4-5 テキストカバー率調査

「読解基本語彙1万語」を評価するため, テキストカバー率調査を行った(表7, 8)。ここでは「出題基準」との比較も行い, コーパス準拠の「読解基本語彙」が本当に実際のテキスト読解に役立つ語彙を選定しているかを検証した。調査には旧日本語能力試験・読解過去問題のテキスト(以下, 「過去問」と), 日本語母語話者向けに書かれた一般のテキストを使用した。

過去問では, 1, 2級は5年分(2005～2009年, 1級: 14096語, 2級: 12334語), 3, 4級10年分(2000～2009年, 3級: 6640語, 4級: 5347語)を使用した。3, 4級を10年分としたのは, 読解テキストの分量が少ないためである。

テキストカバー率調査では, まず, テキストすべてを級別に結合して形態素解析し, 語彙リストの形に変えた。そして, 「読解基本語彙1万語」と同じ基準で機能語, 固有名詞, 一部の対概念語等を削除したうえで語彙の重なりを調査し, テキストカバー率とした。また, 「出題基準」も同じ方法でテキストカバー率を出すため, 語の単位や表記のほか, 見出し語項目の細かい部分は可能な限り「読解基本語彙1万語」と同じ形態素解析結果の形に合わせた。なお, 表8に示される括弧内の数字は調整後の語数で, 「出題基準」では1級8009語, 2級5035語, 3級1409語, 4級728語が公開されている。

表7 JLPT 過去問における「読解基本語彙 1 万語」のテキストカバー率

語彙レベル \ テキスト	1 級読解テキスト	2 級読解テキスト	3 級読解テキスト	4 級読解テキスト
2000 語まで	74%	79%	89%	88%
4000 語まで	84%	88%	94%	93%
6000 語まで	89%	92%	97%	96%
8000 語まで	91%	94%	97%	96%
10000 語まで	93%	95%	98%	97%

表8 JLPT 過去問における「出題基準」のテキストカバー率

語彙レベル \ テキスト	1 級読解テキスト	2 級読解テキスト	3 級読解テキスト	4 級読解テキスト
4 級語彙まで (545 語)	36%	42%	69%	86%
3 級語彙まで (1104 語)	52%	59%	87%	90%
2 級語彙まで (4332 語)	81%	86%	96%	96%
1 級語彙まで (7129 語)	88%	91%	96%	97%

その結果、過去問 1 級から 4 級までの「読解基本語彙 1 万語」のテキストカバー率は、10000 語までで 93 ～ 98% の範囲で示された (表 7)。一方、「出題基準」は 1 級まで (削除、修正後の総語数 7163 語) で 88 ～ 97% である (表 8)。内容語に絞って語の単位を揃えると 1 級の総語数は 7129 語になるが、「読解基本語彙 1 万語」の 6000 語レベルのカバー率は 89 ～ 97% なので、4 級テキストを除けば 6000 語レベルでも「出題基準」1 級を上回る。「出題基準」は日本語能力試験向けに作られた語彙リストだが、読解問題テキストでは「読解基本語彙 1 万語」のほうが出題される語彙をやや多く収録するという結果になった。

全体として 1 級読解テキストのテキストカバー率が 95% を上回らないのは低く感じられるが、これには「読解基本語彙 1 万語」が機能語 (高頻度語彙) を含まない内容語のみのリストであることの影響が考えられる。また、日本語は他の言語に比べてカバー率の低い言語であると言われる (秋元 2002)。このような背景にあり、機能語を除いても「読解基本語彙 1 万語」が 2000 語レベルで 1 級読解テキストの 74% をカバーすることは特筆すべき点である。

次に、日本語教育用に加工されていない一般のテキストでも調査を行った。ここでは日本語学習者が目にする可能性のある一般書き言葉テキストとして新聞、小説、Web サイト (ブログ、ショッピングサイト、学校ホームページ、ウィキペディア) を利用したほか、話し言葉コーパスの『BTSJ による日本語話し言葉コーパス』(2011) も調査対象とした。テキストは 1000 字ずつランダムサンプリングし、各ジャンルを総語数 1 万語にまとめた。

その結果、「読解基本語彙 1 万語」10000 語レベルまでのテキストカバー率は 85% ～ 86% であった (表 9)。これも機能語まで含めれば、より高いカバー率が見込まれる。テキストジャンル別にはカバー率に大きな違いはなく、話し言葉も書き言葉とほぼ同等のカバー率が示された。これは、話し言葉のほう語彙のバリエーションが少ないという一般的な傾向を反映している。特に 2000 語レベルで話し言葉の 65% をカバーした。一方、書き言葉でも「硬い」表現や語彙が多く含まれる新聞では 55% となっていて話し言葉よりも低い値が

示された。これには単語親密度によって身近な語彙のランクを上位に移動させたことの影響も考えられる。このように、「読解基本語彙1万語」は日本語教育的な難易度補正を加えたことで、話し言葉にもある程度対応しうる語彙リストとなっている。

表9 一般テキストにおけるテキストカバー率(比較)

テキストカバー率 語彙レベル	新聞	Web	小説	話し言葉 (雑談)
2000語まで	55%	58%	62%	65%
4000語まで	70%	71%	73%	78%
6000語まで	77%	78%	79%	81%
8000語まで	83%	83%	83%	85%
10000語まで	86%	85%	86%	86%
1級語彙まで	75%	76%	80%	84%

一般テキストにおける「出題基準」1級までの語彙(対象外の語彙の削除および修正後の7163語)のテキストカバー率は、新聞が75%、Webが76%、小説が80%、話し言葉(雑談)が84%であった。これを「読解基本語彙1万語」の8000語レベルと比較すると、新聞が83%、Webが83%、小説が83%、話し言葉(雑談)が85%であり、全て上回っていた。さらに、6000語レベルでも新聞が77%、Webが78%で「出題基準」1級を上回った。

ただし、小説と話し言葉では「出題基準」1級が「読解基本語彙1万語」6000語レベルとの比較において同等かそれ以上のカバー率になることも示されている。これは「出題基準」が日本語教育の現場や教科書の語彙調査などを受けて会話を重視した語彙選定を行っていることを示唆している。小説は会話文も多く含むため、書き言葉としては比較的話し言葉的な語彙を多く含むテキストであると考えられる。同時にこの結果は、「読解基本語彙1万語」が話し言葉よりも書き言葉の語彙を中心とするという特徴を示している。

5. まとめと今後の課題

本研究ではコーパスに基づき「読解基本語彙1万語」を作成した。統計指標を基軸とした語彙選定を行い、レベル分けの区分や語数を設定し、単語親密度で語彙の難易度ランクを調整する方法によって、従来の専門家判定方式による語彙リストとは質的に異なる、言語使用の実態を反映した日本語教育語彙リストの作成を目指した。テキストカバー率調査によって語彙リストを評価した結果、「読解基本語彙1万語」は、日本語能力試験過去問題でも日本語母語話者向けの一般のテキストでも高いカバー率を示した。それは、ほとんどのテキストで「出題基準」のカバー率を上回る結果となった。

本研究で作成した「読解基本語彙1万語」は、日本語学習での利用が見込まれるほか、教材やテストの作成、さらには言語能力試験の内容評価に適用することができる。特に、「出題基準」のような専門家判定方式の語彙リストには収録されていないが実際には様々な日本語テキストに高頻度かつ分布も安定して出現する語彙を抽出しており、専門家判定方式で見落とされている可能性のある重要語彙をリスト化すれば、今後の語彙リスト作りの資料としても利用できる。なお、現在、「読解基本語彙1万語」を利用したWebツールのベ

タ版を公開している (<http://yukari.overworks.jp/>)。これは、あるテキストに含まれる語彙が「読解基本語彙1万語」のどのレベルに該当するかを自動でチェックし、それをリスト化するものである。また、語彙リストそのものの公開も順次行う予定である。

今後の課題には、頻度ランク5～6000語範囲に見られる語彙分布の閾値の検証と精緻化、語彙リストの実用側面の機能強化がある。4-3でレベル分けの語数設定をするため、クラスタ分析によって語彙の頻度と分布傾向を調査した結果、コーパス内の出現頻度ランク6000語水準に一つの閾値があることが分かった。つまり6000語程度までは、サブコーパス間で共通する語彙が多いが、この水準を超えると極端に語彙の共通性が低下する。これは分野依存性が強くなるからであり、語彙の汎用的な使用領域（基本語彙）と個別的な使用領域（専門語彙）の峻別を示唆している。この現象について調査を進め、さらに6000語を精緻化することで、日本語教育上重要度の高い読解基本語彙を提示したい。また、4-1でも述べた通り、コーパス・バランスが異なると、語彙のランク移動がどの程度起こるのかについても、この語彙分布の調査のなかで明らかにしていきたい。

2点目の実用側面の機能強化は、語彙リストの見出し語の単位や表記に関する。目下のところ本語彙リストの見出し語は形態素解析による語彙素表記であり、語の単位も短単位のままで、複合語情報も不十分である。今後はこれらにも取り組み、語彙リストの改善に努めたい。

謝辞

本稿は東京外国語大学地域文化研究科に提出した博士論文の一部をまとめたものである。懇切にご指導くださった東京外国語大学の投野由紀夫先生と、副査として貴重なご助言をくださった佐野洋先生に深謝する。また、本研究の語彙リストを利用したウェブ上の語彙チェックツール作成にご協力くださった東京国際大学の川村よし子先生に心より謝意を表する。

付記

本研究はJSPS科研費（基盤（C）18K00708）の助成を受け、「日本語教育語彙リストの開発—読解語彙6000語の選定—」として継続している。

注

- (1) 日本語教科書は、その作成者が日本語教育上重要と考える、いわゆる主観で選んだ語彙を収録したものと考えることができる。
- (2) 単独で用いられた場合、語彙的意味をほぼ持たないが文法的機能を有する語である機能語（助詞、助動詞など）は、日本語教育では文型の中で扱われることが多い。本研究は、文型までは分析に含めておらず、日本語の書き言葉を読む際に意味を知っているとテキストの理解に役立つ語彙、特に内容語を抽出することを主な目的としているため、機能語を削除した。
- (3) 『現代日本語書き言葉均衡コーパス』（国立国語研究所2011）は13種類（書籍・流通、ベストセラー、Yahoo!知恵袋、国会会議録、広報紙、韻文、検定教科書、白書、Yahoo!ブログ、書

籍・生産、雑誌、新聞、法律)の異なるレジスターで構成されている。

- (4) 法律 (OL) の語彙は専門的、特殊であり、これを含めると全体の語彙の重なり割合が極端に低くなるため初めから除外した。法律 (OL) のような特殊な書き言葉を一般の日本語学習者が読む可能性は低く、日本語学習者が書き言葉を読むときに知っている役立つ語彙を抽出するという本研究の目的において、このレジスターがあまり重要ではないことも理由に含まれる。

また、総語数が約25万語の韻文 (OV) についても、ここで行う100万語単位の比較には語数が少なすぎ、単純な比較を行えないため分析には含めなかった。そのため、ここでの比較は13種類のレジスターのうち11種類で行っている。

- (5) 基本語彙は、語彙調査で使用率が高く使用範囲が広いとされる語彙、コーパスでは高頻度で分布が安定した語彙を指す。これに対して専門語彙という概念がある。専門語彙とは「ある特定の専門分野に顕著に多く現れる語彙」である。一般的に基本語彙を学習した後、学習者のニーズに応じて専門語彙を指導すると学習効率が上がると言われている (中條 2009, p.10)。
- (6) Gries (2008) は、Juilland's *D* や Carroll's *D2* は0から1の範囲で示される指標だが実際はこの範囲を超える場合があること、全てのファイルに同じ頻度で出現するなら散布度の値は1、一つのファイルに1回しか出現しなければ0に理論上はなるはずだが実際にはそのようにならない場合もあること、その他、指標の感度の問題などを指摘している。Gries (2008) はこのような問題を解消した指標として *DP* を提唱している。
- (7) 本研究ではレジスター間の散布度を計算している。
- (8) この他、(1-*DP*) で計算するという方法も考えられる。どちらが妥当であるかの検討は、今後の課題としたい。
- (9) 本研究における対概念語とは、互いに対照的な要素を持ち、一方が言及される場合には自ずと他方の存在が前提とされるような関係の語彙を指す。例えば、数詞はこれに当たる。日本語教育で、例えば1から100までの数字を教える場合、一般的にはひとまとまりの学習項目として扱い、数字の一つ一つを別々に「1」は初級、「19」は中級というようなレベル分けにすることはまずない。しかし、頻度と分布だけで語彙をランキングした場合、これらが異なるレベルに配置される可能性がある。そのような区分は本研究の目的と合うものではなく、また、日本語教育的にも意味がないと言える。このような理由から、数詞をはじめとする対概念語をリストから除外した。今後、これらをまとめた追加語彙リストを作成する予定である。
- (10) 「出題基準」では1級語彙として8009語を公開している。このレベルと比較する際に、8000語レベルがあると結果がわかりやすい。
- (11) 単語親密度には、文字音声単語親密度、音声単語親密度、文字単語親密度の3種類がある。
- (12) 例えば、「くれる」は「呉れる」と表され、文字音声単語親密度は3.438、音声単語親密度は5.625である。この差は表記のなじみのなさが影響して生じると考えられ、このタイプを調整対象とした。

参考文献

- (1) 饗場淳子 (2011)「日本語教育用語彙に共通する語についての一考察」『早稲田大学大学院教育学研究科紀要』, 18-2.
- (2) 秋元美晴 (2002)『日本語教師・分野別マスターシリーズ よくわかる語彙』アルク.
- (3) 宇佐美まゆみ監修 (2011)『BTSJによる日本語話し言葉コーパス』東京外国語大学.
- (4) 押尾和美, 秋元美晴, 武田明子, 阿部祥子, 高梨美穂, 柳沢好昭, 石毛順子 (2008)「新しい日本語能力試験のための語彙表作成にむけて」『国際交流基金 日本語教育紀要』第4号, 71-86.
- (5) 川村よし子 (2006)「日本語学習者のための基本語選定の一試案」『ヨーロッパ日本語教育』vol.11, 72-78.
- (6) 国際交流基金・(財)日本国際教育支援協会 (2006)『日本語能力試験出題基準改訂版』凡人社.
- (7) 国立国語研究所 (2011)『現代日本語書き言葉均衡コーパス』国立国語研究所.
- (8) 中條清美 (2009)「指導に役立つ語彙リスト紹介」『G.C.D. 英語通信』No.46.
- (9) 寺田博視・田中久美子 (2008)「単語親密度と単語頻度の関係に関する一考察」言語処理学会 第14回年次大会 発表論文集, 713-716.
- (10) 投野由紀夫・本田ゆかり (2016)「第2章 教育語彙表への応用」砂川有里子 (編)『講座日本語コーパス5 コーパスと日本語教育』朝倉書店, 35-57.
- (11) 徳弘康代 (2005)「中上級学習者のための漢字語彙の選択とその提示法の研究」『日本語教育』127号, 41-50.
- (12) 本田ゆかり (2015)「大規模コーパスに基づく日本語教育語彙表の作成」東京外国語大学大学院地域文化研究科博士論文.
- (13) 松下達彦 (2011)「日本語を読むための語彙データベース」(The Vocabulary Database for Reading Japanese). 参照先: <http://www17408ui.sakura.ne.jp/tatsum/LTVJ/index.html>
- (14) 宮本聡介・太田信夫編著 (2008)『単純接触効果の最前線』北大路書房.
- (15) 李在鎬, 砂川有里子 (2012)「コーパスを活用した日本語語彙表の構築」2012年日本語教育国際研究大会 (ICJLE2012) パネルセッション 日本語教育につながるコーパス研究—現状と今後の展望—.
- (16) Gries, S. (2008). Dispersions and adjusted frequencies in corpora. *International Journal of Corpus Linguistics* 13 (4), 403-437.
- (17) Tono, Y. (2013). Sampling biases and implications for better wordlist creation. Vocab@Vic conference, presentation slides. Victoria University of Wellington.

(東京外国語大学)

Compiling a Corpus-based Educational Word List for Learners of Japanese: “Basic Vocabulary of 10,000 Words for Reading Japanese Text.”

HONDA Yukari

The purpose of this research was to compile a corpus-based educational word list (hereinafter referred to as, “the List”) for learners of Japanese as a foreign language. The List is a receptive vocabulary list used for reading Japanese text. The importance of each word in learning Japanese was quantified by dispersion and utility measurements. The level of each word in the List was determined by its rank for word importance and word-familiarity which indicates the difficulty of the word.

To assess the practicality of the List, a text coverage survey was conducted. It was found that text coverage of the vocabulary in the List was wider for text used by native speakers and text written for Japanese language learners than the JLPT word list.

(Tokyo University of Foreign Studies)